
Comparativa de algoritmos de Machine Learning para la detección temprana de diabetes en mujeres



Trabajo de Fin de Máster

Curso 2025-2026

Autora

Yaiza Nerea Barrera de la Cruz

Profesor Especialista

Cristian Rodríguez

Máster en Aplicaciones de la IA en Salud

Centro Europeo de Máster y Posgrados CEMP

Índice

1.Abreviaturas	1
2.Introducción	2
3.Materiales y Métodos	6
3.1. Dataset	6
3.2. Preprocesamiento de datos	7
3.2.1. Inspección y análisis exploratorio inicial	7
3.2.2. Identificación y tratamiento de valores no plausibles	8
3.2.3. Análisis exploratorio final	9
3.2.4. División en conjuntos de entrenamiento y test	13
3.2.5. Imputación de valores faltantes	14
3.2.6. Desbalanceo de clases y escalado	15
3.3. Modelado.....	17
3.3.1 Modelos de clasificación	17
3.3.2 Métricas de evaluación.....	17
3.3.3 Validación cruzada	18
3.3.4 Optimización de hiperparámetros	19
3.3.5 Modelo final seleccionado.....	19
3.3.6 Implementación y despliegue.....	20
4.Resultados y Discusión	21

4.1 Análisis exploratorio	21
4.2 Comparación de modelos	23
4.3 Interpretación del modelo	25
5. Conclusiones	28
6. Limitaciones y Trabajo futuro	30
7. Bibliografía.....	32
8. Anexos	39
8.1. Anexo 1 - Código.....	39

1.Abreviaturas

Abreviatura	Definición
OMS	Organización Mundial de la Salud
ML	Machine Learning
ROC-AUC	Receiver Operating Characteristic – Area Under the Curve
SMOTE	Synthetic Minority Over-Sampling Technique
NIDDK	National Institute of Diabetes and Digestive and Kidney Disease
BMI /IMC	Body Mass Index / Índice de Masa Corporal
IQR	Rango intercuartílico
KNN	Vecinos más cercanos (K-Nearest Neighbors)
SVM	Support Vector Classifier
CDSS	Sistemas de Soporte a la Decisión Clínica

2.Introducción

La diabetes mellitus tipo II es una enfermedad metabólica crónica, caracterizada por hiperglucemia persistente debida a una combinación de resistencia a la insulina y, deterioro progresivo de la secreción de insulina. Su importancia no solo recae en su prevalencia, sino también en la afectación de la calidad de vida del paciente y, su asociación con complicaciones graves sino se diagnostica y trata de forma adecuada (1). Entre estas complicaciones se incluyen enfermedades vasculares, la nefropatía diabética, la neuropatía periférica y la retinopatía, enfermedades que pueden ser prevenibles si siguen controles adecuados o se diagnostica la diabetes a tiempo (2).

Según la Organización Mundial de la Salud (OMS), la diabetes constituye uno de los principales retos de la salud pública a nivel global, con crecimiento sostenido de la carga epidemiológica en las últimas décadas. Informes recientes muestran que el número de adultos con diabetes continúa creciendo, incluso que existe desconocimiento por parte de la población de su condición clínica, lo que refuerza la necesidad de estrategias de detección precoz y cribado más eficaces. Además, la carga sanitaria y económica asociada, no se debe solo al aspecto del tratamiento, sino también en la atención de sus complicaciones, como la monitorización continuada y la pérdida de productividad por su evolución crónica. De esta manera, la diabetes de tipo II no solo representa un problema asistencial, sino también un desafío de sostenibilidad para el sistema sanitario. (3,4)

La detección temprana de la diabetes resulta fundamental para prevenir complicaciones a largo plazo, mejorar la calidad de vida de los pacientes y reducir su impacto clínico. Un diagnóstico tardío implica que la enfermedad progrese sin tratamiento, persistiendo un estado de hiperglucemia, que favorece el daño acumulativo sobre diferentes órganos y sistemas (4). En este contexto, los sistemas de cribado tradicionales de umbrales clínicos resultan insuficientes para la identificación precoz y eficiente de los casos de riesgo en grandes poblaciones. Este hecho ha impulsado el campo del aprendizaje automático en este ámbito. Los métodos complementarios de predicción clínica pueden servir como herramientas capaces de identificar la enfermedad a partir de variables clínicas recogidas en la práctica rutinaria clínica. (5)

En los últimos años, el aprendizaje automático ha adquirido un papel creciente en la predicción de enfermedades crónicas. Estos sistemas presentan la ventaja de poder analizar simultáneamente múltiples variables clínicas y detectar relaciones no lineales que pueden pasar desapercibidas con análisis convencionales. Los modelos de *Machine Learning* (ML) se han convertido en herramientas prometedoras para la ayuda de la decisión clínica. Aun así, se ha de tener en cuenta que el rendimiento del modelo no solo debe ser medido en términos de exactitud global, sino también en función de las métricas que sean clínicamente relevantes para el problema en cuestión. (6,7)

Una cuestión importante en el ámbito sanitario es el balance entre falsos positivos y falsos negativos. En el caso de la diabetes, un falso negativo implica una detección tardía de la enfermedad, pudiendo dar lugar a las complicaciones mencionadas anteriormente. Por el contrario, en el caso de falsos positivos, las posibles consecuencias son generar pruebas adicionales, pero no suele conllevar a un riesgo clínico. Por esta razón, en trabajos de predicción clínica suele priorizarse métricas como la sensibilidad. El objetivo principal es no dejar casos positivos sin diagnosticar. La curva ROC (*ROC-AUC Receiver Operating Characteristic – Area Under the Curve*), permite evaluar la capacidad global del modelo para discriminar entre clases, independientemente del umbral de decisión que haya sido marcado. Gracias a esto, se obtiene una visión más completa del rendimiento de los modelos, sobre todo cuando es relevante analizar el equilibrio entre sensibilidad y especificidad. (6)

El presente Trabajo de Fin de Máster pretende adentrarse en este marco de investigación con el fin de desarrollar y evaluar un modelo de clasificación supervisada, para la predicción de diabetes mellitus tipo II. La predicción se llevará a cabo en la población femenina del *dataset Pima Indians Diabetes*, por lo que este modelo de predicción solo podrá ser aplicado a mujeres. Este *dataset* está compuesto de diferentes variables clínicas clásicas (8), y ha sido utilizado ampliamente en investigación por su relevancia histórica. Las variables clínicas son: número de embarazos, niveles de glucosa, presión arterial, grosor del pliegue cutáneo, niveles de insulina, índice de masa corporal, función de pedigrí diabético y edad. (9)

Se compararon cuatro algoritmos de aprendizaje automático: Regresión Logística, *Random Forest*, *Support Vector Classifier* y *XGBoost*. La selección de estos modelos responde a la necesidad de abarcar aproximaciones lineales y no lineales, como también modelos interpretables y modelos de ensamblado con capacidad de capturar relaciones complejas. La Regresión Logística se utilizó como modelo de referencia por su interpretabilidad. (10) *Random Forest* (11) y *XGBoost* (12) se eligieron porque permiten modelar interacciones no lineales entre variables clínicas. SVC es útil en espacios con relaciones complejas y fronteras de decisión no triviales (13). Escoger modelos que utilizan diferentes enfoques, permite valorar cuál de ellos ofrece un mejor equilibrio entre rendimiento, sensibilidad e interpretabilidad al problema (14).

Para evaluar los modelos se utilizaron métricas de clasificación que son ampliamente aplicadas en aprendizaje automático en el ámbito de la salud. Estas métricas son: exactitud, precisión, *recall* o sensibilidad, F1-score, especificidad, matriz de confusión y ROC-AUC. Aun así, dada la naturaleza del problema, se priorizaron 2: sensibilidad y ROC-AUC. Esto se debe al objetivo principal de la minimización de los falsos negativos. Por lo tanto, en cuanto a la elección final del mejor modelo, no se tendrá en cuenta únicamente las métricas globales, sino los mejores valores de aquellas que estén más alineadas con el objetivo clínico. (6,15) La combinación de ambas métricas permitirá seleccionar modelos que no solo detecten correctamente los casos positivos, sino que también mantengan una adecuada capacidad discriminatoria general. (16)

El pipeline metodológico del trabajo incluyó: la carga y exploración inicial del conjunto de datos, la identificación de valores no plausibles, el tratamiento de valores faltantes (17), el manejo del desbalanceo de clases a partir de SMOTE (*Synthetic Minority Over-sampling Technique*) (18), normalización de las variables (19), como también el entrenamiento de los modelos, su validación a través de una validación cruzada (20) y la optimización de los hiperparámetros (21). Además, se realizó un análisis de la importancia de variables con el fin de identificar los predictores clínicos más relevantes, aportando interpretabilidad a los resultados obtenidos. (22)

En conjunto, este Trabajo de Fin de Máster pretende responder tres preguntas principales. En primer lugar, si es posible predecir la presencia de diabetes a partir de variables clínicas básicas con un rendimiento aceptable para su uso como una herramienta de apoyo

a la decisión clínica. En segundo lugar, qué algoritmo de aprendizaje automático ofrecen la mejor sensibilidad en la detección de casos positivos, minimizando los falsos negativos. Y, en tercer lugar, qué variables clínicas presentan mayor capacidad predictiva y si dichas variables son coherentes con la evidencia clínica. Estas preguntas serán las que articulen el desarrollo del estudio y justifiquen tanto la elección del *dataset* como la estrategia metodológica.

El presente trabajo no pretende sustituir el juicio clínico, sino explorar la viabilidad de herramientas computacionales para la ayuda en la evaluación clínica mediante aproximaciones basadas en datos que sean reproducibles.

3. Materiales y Métodos

3.1. Dataset

El conjunto de datos utilizado en este estudio corresponde al *Pima Indians Diabetes Database*, proveniente del *National Institute of Diabetes and Digestive and Kidney Disease* (NIDDK) (23). Este *dataset* es un recurso clásico en investigación biomédica y en aprendizaje automático aplicado a la salud (7). La población representada en los datos corresponde a mujeres de origen indígena Pima de al menos 21 años. Se trata de una población clínicamente relevante, ya que presenta una alta prevalencia de diabetes mellitus tipo II a nivel mundial, por esta razón, es un *dataset* clínicamente relevante y representativo para condiciones de diabetes. (24)

El *dataset* está compuesto por 768 registros y 9 variables, de las cuales 8 son variables predictoras y 1 variable objetivo. Las variables predictoras son: número de embarazos (*Pregnancies*), glucosa plasmática (*Glucose*), presión arterial (*BloodPressure*), grosor del pliegue cutáneo (*SkinThickness*), insulina sérica (*Insulin*), Índice de Masa Corporal (*IMC*, *Body Mass Index BMI*), función de pedigrí diabético (*DiabetesPedigreeFunction*) que cuantifica la predisposición genética a la enfermedad, y edad (*Age*). La variable objetivo es *Outcome*, variable dicotómica que indica la presencia (1) o ausencia (0) de diabetes siendo el resultado que el modelo debe aprender. (23)

Todas las variables del conjunto de datos son de tipo numéricas; siendo la mayoría de tipo entero y dos de tipo flotante, *BMI* y *DiabetesPedigreeFunction*. Al ser todas de tipo numéricas, facilita su procesamiento mediante técnicas de ML sin necesidad de codificación de variables categóricas. Además, no se detectaron valores duplicados en la revisión inicial del *dataset*. No obstante, una de las principales limitaciones del conjunto de datos es el desbalanceo de clases, con una mayor proporción de casos negativos (65,1% *Outcome*=0) que casos positivos (34,9% *Outcome*=1). Este aspecto es importante a la hora de construcción del modelo porque el desbalance de clases puede influir en el rendimiento y en la interpretación de las métricas. (25)

3.2. Preprocesamiento de datos

El preprocesamiento de datos constituye una etapa fundamental en los estudios de ML. La calidad de los datos condiciona la validez del modelo final, es por este motivo, que la fase de preprocesamiento de datos se diseñó con el objetivo de mejorar la consistencia de la información. Sobre todo, reducir el sesgo introducido por valores no plausibles y preparar los datos para la fase de entrenamiento. (22)

3.2.1. Inspección y análisis exploratorio inicial

En primer lugar, se realizó un análisis exploratorio inicial de los datos para conocer su estructura general, identificar posibles problemas de calidad de los datos, y comprender la distribución de las variables. Esta etapa confirmó que el conjunto de datos estaba compuesto por 768 pacientes, con 8 variables predictoras y 1 variable objetivo. Todas las variables eran de tipo numérico, lo que simplificaba la integración de los algoritmos de ML utilizados posteriormente. (25)

No se detectaron valores duplicados en el *dataset*. La comprobación básica de valores nulos, gracias a la función *isnull()* de pandas, no mostró valores faltantes aparentes en ninguna de las variables. Sin embargo, el análisis descriptivo mediante *df.describe()*, reveló valores mínimos iguales a 0 en las variables *Glucose*, *BloodPressure*, *SkinThickness*, *Insulin* y *BMI*. Desde el punto de vista clínico, un valor mínimo de 0 de estas variables es fisiológicamente implausible (8,26). Este hallazgo sugirió que los *missing values* estaban codificados como 0, aspecto que se abordará en el apartado 2.2.2. Esta es una práctica conocida en algunos conjuntos de datos biomédicos. (27) Además, se observó una mayor intensidad de este fenómeno en *SkinThickness* e *Insulin*, donde los valores de sus percentiles 25% es de 0, sugiriendo una alta proporción de valores faltantes (28). Este hallazgo fue relevante ya que la presencia de valores faltantes que no han sido tratados puede distorsionar la distribución de las variables y afectar al rendimiento del modelo (29).

Además, el análisis descriptivo permitió observar asimetrías en las distribuciones de variables como *Pregnancies*, *Insuline* y *Age*. Presentaban valores de media mayores a la mediana, percentil 50%, sugiriendo una distribución desplazada a la derecha. Este resulta

un comportamiento habitual en variables biomédicas y, refuerza la necesidad de aplicar técnicas de imputación y escalado (30).

Por último, la variable *Outcome* era de tipo binario, indicaba la presencia o ausencia de la enfermedad, por lo tanto, el problema era una tarea de clasificación supervisada. (31)

3.2.2. Identificación y tratamiento de valores no plausibles

Una de las características más conocidas del *Pima Indians Diabetes Database* es que algunos valores faltantes no aparecen como nulos explícitos, si no que están codificados como valores 0 (8). Para identificarlos, se analizó la presencia de valores iguales a 0 en aquellas variables en que dicho resultado era fisiológicamente implausible. Como se muestra en la Tabla 1, se identificaron 5 variables afectadas: *Glucose*, *BloodPressure*, *SkinThickness*, *Insulin* y *BMI*(23).

Variable	Número de valores 0	Porcentaje de valores faltantes (%)
Insulin	374	48.7
SkinThickness	227	29.56
BloodPressure	35	4.56
BMI	11	1.43
Glucose	5	0.65

Tabla 1. Valores 0 y porcentajes (%) en variables clínicamente implausibles.

Las variables *Pregnancies* y *Outcome*, no se consideraron afectadas por el problema, ya que un valor de 0 sí que tenía una interpretación clínica real en ambos casos; ausencia de embarazos previos y, ausencia de la enfermedad. Sin embargo, valores 0 en variables como glucosa, presión arterial o insulina no tenían sentido fisiológico y fueron interpretados como datos faltantes (8,23,26).

La variable *Insulin* era la que presentaba mayor porcentaje de valores faltantes (48,7%), seguida de *SkinThickness* (29.56%). Las variables que presentaban una tasa baja de porcentaje de valores faltantes eran *BloodPressure*, *BMI* y *Glucose*, con un porcentaje menor al 5%.

Para que los algoritmos de imputación pudieran operar y detectar los valores faltantes, los 0 implausible debían ser transformados a valores NaNs. Fueron convertidos a valores NaNs mediante la función *replace()* de pandas, lo que generó 652 valores nulos entre las 5 variables afectadas (22,32). Esta transformación permitió la aplicación de estrategias de imputación según el porcentaje de valores faltantes de cada variable.

3.2.3. Análisis exploratorio final

El análisis exploratorio final se realizó tras la conversión de los 0 no plausibles a NaNs y, previo a la separación de *train* y *test* (22). El objetivo era realizar una exploración descriptiva para observar las relaciones entre las variables y la variable objetivo. Se siguió este orden para evitar sesgos o fugas de información en las fases posteriores del análisis (33).

Se calculó la matriz de correlación de Pearson (Figura 1) entre las variables numéricas, con el objetivo de identificar las variables más relevantes para la predicción de la diabetes. Los resultados mostraron que las tres variables que presentaban mayor correlación con *Outcome* eran *Glucose* ($r=0,49$), *BMI* ($r=0,31$) e *Insulin* ($r=0,3$). Los niveles altos de glucosa en sangre constituyen el predictor más relevante desde el punto de vista estadístico (1), resultado coherente a la realidad clínica. Además, se observaron relaciones moderadas entre las variables metabólicas *Insulin* y *Glucose* ($r=0,58$) y *SkinThickness* y *BMI* ($r=0,65$), esperable en el contexto clínico (22).

Una perspectiva importante es que, al convertir los 0 en NaNs, la variable *Insulin* ganó relevancia en su correlación con la variable objetivo. Este hecho pone de manifiesto las consecuencias de los valores faltantes en la distorsión de las relaciones entre variables, y la importancia de la adecuada preparación de los datos anterior a su análisis (26,27).




Figura 1. Matriz de correlación de Pearson de todas las variables predictoras.

Se emplearon diagramas de cajas para analizar la distribución de las variables clínicas que presentaban mayor correlación con *Outcome* según el *heatmap*. El objetivo era evaluar la capacidad discriminativa entre ambos grupos.




Figura 2. Boxplot de los niveles de glucosa según la presencia de diabetes.




Figura 3. Distribución de la variable objetivo Outcome.

El bloxplot de los niveles de glucosa según la presencia de diabetes (Figura 2), evidenció como los pacientes con *Outcome*=1 mostraban niveles superiores de glucosa. Presentaban una mediana de 140 mg/dL frente a una mediana de alrededor 110 mg/dL de los casos sin diabetes. También se observaron diferencias significativas en los diagramas de cajas de *BMI* e *Insulin*, lo que sugirió que eran factores de riesgo relevantes para la población (34). No obstante, existía cierto solapamiento entre las diferentes clases, indicando que el problema de clasificación requería el uso de modelos de ML para capturar relaciones complejas. Esta premisa también se apreció gracias al *scatterplot* de *BMI* y *Glucose*, el cual presentaba cierto solapamiento de las dos clases, y una concentración de casos positivos en niveles altos de glucosa, reforzando su papel predictor (22,35).

El análisis del balance de clases (Figura 3) confirmó la presencia de un ligero desbalanceo entre los dos estados de la variable objetivo (36). Se encontró que la clase ausencia de enfermedad estaba más representada, con 500 casos, mientras que la clase presencia de enfermedad solo presentaba 268 casos. Este resultado debía tenerse en cuenta por la influencia en el rendimiento de los modelos y la selección de métricas de evaluación, priorizando la sensibilidad y el AUC-ROC.




Figura 4. Histogramas de las distribuciones de las variables predictoras.

La visualización de la distribución de variables (Figura 4) confirmó lo predicho en el apartado 2.2.1. *Pregnancies*, *Insulin*, *DiabetesPedigreeFunction* y *Age* mostraron cierta asimetría en su distribución con sesgos positivos y colas largas hacia la derecha. *Glucose* y *BloodPressure* mostraban distribuciones más equilibradas, y *BMI* y *SkinThickness* casi simétricas con un ligero sesgo a la derecha (37).

La detección de valores atípicos (Tabla 2) se llevó a cabo con el método más común, el método del rango intercuartílico (IQR). Este método determina cualquier valor inferior a $Q1 - 1,5 * IQR$ y cualquier valor superior a $Q3 + 1,5 * IQR$ se considerará atípico (38). Los resultados mostraron la presencia de valores atípicos en todas las variables menos en glucosa. Las que presentaron valores más altos de *outliers* fueron *Insulin* y *DiabetesPedigreeFunction*.

Variable	Total Valores Atípicos	Porcentaje Valores Atípicos (%)
Insulin	24	6.09
DiabetesPedigreeFunction	29	3.78
BloodPressure	14	1.91
Age	9	1.17
BMI	8	1.06
SkinThickness	3	0.55
Pregnancies	4	0.52
Glucose	0	0.0

Tabla 2. Presencia de valores atípicos en variables predictoras y sus porcentajes.

Sin embargo, los valores no fueron eliminados por dos motivos principales. En primer lugar, por razones clínicas, ya que pueden corresponder a valores reales con posible relevancia clínica, como indicadores de obesidad mórbida o de resistencia severa a la insulina. Por lo tanto, su eliminación causaría sesgos en el modelo hacia casos moderados, reduciendo la capacidad de detección en pacientes más graves (22).

En segundo lugar, por razones metodológicas. Como el objetivo prioritario del modelo era minimizar los falsos negativos, los valores extremos de variables como glucosa o insulina suelen corresponder a casos positivos más evidentes de diabetes. De este modo, eliminarlos podría reducir la capacidad de detección de estos casos (22).

3.2.4. División en conjuntos de entrenamiento y test

La división de los conjuntos de entrenamiento y prueba se realizó a priori a la imputación de los valores faltantes. Esta decisión metodológica fue tomada para evitar el fenómeno de *data leakage*. Realizar la imputación antes de separar los datos, introduciría información del conjunto test en el conjunto de entrenamiento, dando unas métricas de rendimiento más altas y poco realistas, por eso fue una decisión esencial en el desarrollo de modelos de ML (33). El objetivo de la división era la evaluación del rendimiento de los modelos de aprendizaje automático (39).

Para llevarlo a cabo, se separaron las variables predictoras (x), de la variable objetivo (y). Siguiendo la práctica habitual para problemas de clasificación, se les aplicó una partición de proporciones 80/20, siendo el 80% de los datos destinados a entrenamiento y el 20% para prueba. Una correcta separación de los datos permite evitar sobreajustes y obtener

estimaciones realistas en el rendimiento (22). Para asegurar la reproducibilidad de los resultados, se fijó una semilla aleatoria (*random_state=42*). Asimismo, también se empleó el parámetro *stratify=y* con el objetivo de mantener la estratificación de clases en los dos subconjuntos dado que el *dataset* presentaba un desbalanceo de clase, comentado anteriormente (14,40).

Como resultado, el conjunto de entrenamiento y de prueba eran representativos a la distribución original de los datos. El conjunto de entrenamiento estaba compuesto por 614 observaciones y, el grupo de prueba por 154. Las distribuciones de las clases fueron de 65,1% y 34,9% en el set de entrenamiento, y de 64,9% y 35,1% en el set de prueba, muy similares a la distribución del conjunto original. Esta distribución confirmó que la división de los conjuntos funcionó correctamente, y que ambos eran representativos de la distribución global (40).

3.2.5. Imputación de valores faltantes

Una vez realizada la separación de los datos en *train* y *test*, se realizó la imputación (26) de los valores faltantes identificados en el apartado 2.2.2.

Se aplicaron dos estrategias de imputación en función del porcentaje de valores faltantes según el criterio de Salgado et al. (41). Para las variables con un porcentaje de valores faltantes bajo (<5%), se aplicó una imputación simple mediante la mediana (27). Este método resulta más robusto que la media en caso de valores atípicos, preservando mejor la distribución general de las variables. Las variables a las que se les aplicó la imputación simple fueron: *BloodPressure* (3,75%), *BMI* (1,47%), y *Glucose* (0,65%).

Para las variables con un porcentaje elevado de valores faltantes (>5%), se aplicó un método de imputación basado en vecinos más cercanos (KNN) con $k=5$ (42). Este método estima los valores faltantes a través de la similitud entre observaciones, por eso fue una alternativa más adecuada cuando la tasa de valores faltantes es elevada. Las variables imputadas mediante KNN fueron: *SkinThickness* (28,5%) e *Insulin* (47,23%).

En ambos casos se siguió el patrón *fit/transform* (33). El imputador aprende los estadísticos del conjunto de entrenamiento (*x_train*) y, se aplican los mismos criterios al conjunto de prueba (*x_test*). De esta manera, se reproduce un escenario realista para el

uso del modelo, en la que la imputación de x_{test} simula las condiciones reales de producción. Nuevos pacientes llegarán para ser tratados y deberán pasar por el mismo proceso de preprocesamiento que los datos de entrenamiento.

Variable	% Valores faltantes	Antes imputación (Media $\pm$ SD)	Después imputación (Media $\pm$ SD)	Mediana antes	Mediana después
Glucose	0.65	121.70 $\pm$ 30.10	121.67 $\pm$ 30.00	117.0	117.0
BloodPressure	3.75	72.15 $\pm$ 12.51	72.14 $\pm$ 12.28	72.0	72.0
SkinThickness	28.5	29.06 $\pm$ 10.52	29.06 $\pm$ 8.89	29.0	29.06
Insulin	47.23	149.08 $\pm$ 107.23	146.31 $\pm$ 81.32	125.0	149.08
BMI	1.47	32.45 $\pm$ 6.87	32.45 $\pm$ 6.82	32.4	32.4

Tabla 3. Tabla comparativa de las estadísticas descriptivas de las variables imputadas antes y después de la imputación.

Tras la imputación, no se observaron valores nulos ni en el conjunto de entrenamiento ni en el de prueba. La Tabla 3 recoge las comparaciones de las estadísticas descriptivas antes y después del proceso de imputación. Las variables imputadas mediante mediana (*Glucose*, *BloodPressure* y *BMI*) no presentaban cambios en sus medianas, solo cambios mínimos en sus medias y desviaciones estándar. Estos resultados confirmaron que la imputación preservó la distribución original de los datos (26). Para las variables imputadas mediante KNN (*SkinThickness* e *Insulin*), se apreció un aumento de la mediana, más notable en *Insulin*. Se observó una reducción moderada de las desviaciones estándar de ambas variables (de 10,452 a 8,89 en *SkinThickness*, y de 107,23 a 81,32 en *Insulin*), mientras que la media de *SkinThickness* era la misma y la de *Insulin* disminuyó ligeramente. Los resultados de esta imputación son esperados ya que este método tiende a suavizar la variabilidad al sustituir los valores extremos por estimaciones centrales.

Los resultados de ambas imputaciones sugirieron que las estrategias seguidas permitieron completar los datos sin alterar de forma sustancial la estructura de las variables.

3.2.6. Desbalanceo de clases y escalado

Tal y como se determinó en el análisis exploratorio, la variable objetivo presentaba un desbalanceo de clases, siendo la clase mayoritaria la de casos negativos (65,10%) y la clase minoritaria la de casos positivos (34,90%). El desbalanceo puede afectar negativamente al rendimiento del modelo de clasificación, ya que se produce un sesgo hacia la clase mayoritaria, la que más está representada. Es decir, que existen afectaciones

en la sensibilidad del modelo y aumentos de los falsos negativos, lo que conlleva a un impacto clínico directo en la detección temprana de la enfermedad (18,36).

Con el objetivo de mejorar la sensibilidad y reducir el número de falsos negativos, se aplicó la técnica SMOTE sobre el conjunto de entrenamiento (18).

La técnica SMOTE funciona generando muestras sintéticas de la clase minoritaria a partir de la interpolación entre instancias existentes de esta clase en el espacio de características, equilibrando así el conjunto de datos sin la necesidad de duplicar registros (18). Lo que se tradujo en pasar de una distribución original en el entrenamiento de 400/214 a una distribución 400/400.

La técnica se aplicó después de imputar ya que necesita datos completos para operar en el espacio de características y, antes de escalar, para mantener la interpretabilidad clínica de las distancias entre observaciones. Asimismo, no se aplicó SMOTE al conjunto de prueba (33) ya que la introducción de puntos artificiales puede influir en la fase de evaluación, haciendo que sea menos realista.

A continuación, se aplicó el escalado de las variables mediante *StandardScaler* de *scikit-learn*, que transforma cada variable para que presente una media cercana a 0 y desviación estándar cercana a 1 (19).

La etapa de escalado es necesaria por dos razones. En primer lugar, porque algoritmos basados en distancias (43) como *Support Vector Classifier* (SVC) son sensibles a las escalas. Esto se traduce en una dominación de las variables que presentan rangos más amplios, como *Insulin* (0-846), frente aquellas con rangos más reducidos, por ejemplo, *DiabetesPedigreeFunction* (0,078-2,42), distorsionando el cálculo de distancias. En segundo lugar, la Regresión Logística (10) converge más rápido y más estable cuando las escalas de las variables son las mismas. En el caso de *Random Forest* y *XGBoost*, como se tratan de algoritmos basados en árboles de decisión, no les afecta de igual forma el escalado (33), aun así, se incluyeron para mantener la coherencia metodológica (12,44).

El escalador fue ajustado sobre el conjunto de entrenamiento (`x_train_smote`), aprendiendo la media y desviación estándar de cada variable del conjunto de entrenamiento balanceado previamente. Posteriormente, se aplicó la transformación al

conjunto de prueba (`x_test_imputed`) y a `x_train_smote`. De esta manera se siguió el principio de prevención de *data leakage*.

3.3. Modelado

3.3.1 Modelos de clasificación

En este estudio se modelaron cuatro algoritmos de clasificación supervisada para predecir la presencia de diabetes en pacientes de sexo femenino, a partir de variables clínicas. Los modelos fueron: Regresión Logística, *SVC*, *XGBoost* y *Random Forest*.

La selección de estos algoritmos estuvo motivada por la necesidad de capturar distintos enfoques de interpretabilidad, capacidad predictiva y modelado de relaciones, abarcando modelos tanto lineales como no lineales, además de su uso ampliamente extendido en problemas de clasificación médica (14,22).

La Regresión Logística se utilizó como modelo base debido a su simplicidad e interpretabilidad (10). Por otro lado, *Random Forest* (44) y *XGBoost* (12) se incluyeron por su capacidad para modelar relaciones complejas mediante ensamblado de árboles. Suelen obtener buenos resultados en datos tabulares clínicos y reducir la varianza del modelo. Asimismo, *SVC* fue seleccionado por su utilidad en espacios de alta dimensionalidad y su capacidad para definir fronteras de decisión no lineales (43).

Todos los modelos fueron entrenados con el conjunto de entrenamiento previamente preprocesado, imputado los valores faltantes, realizado el balanceo de clases mediante SMOTE y habiendo escalado sus variables. De esta manera, se evaluó el rendimiento de los modelos bajo las mismas condiciones metodológicas y de una forma justa.

3.3.2 Métricas de evaluación

Las métricas de clasificación utilizadas para evaluar el rendimiento de los algoritmos fueron: exactitud, precisión, *recall* (sensibilidad), F1-score, ROC-AUC y especificidad. Estas métricas son ampliamente utilizadas en problemas de clasificación en el ámbito biomédico, ya que es necesario evaluar distintos aspectos del rendimiento del modelo (15,16).

Como se ha mencionado en el apartado 2, uno de los objetivos primordiales del estudio era minimizar la tasa de falsos negativos, es decir, evitar que pacientes con diabetes reciban un diagnóstico negativo y no sean identificados por el modelo. Por este motivo, la métrica que se priorizó fue *recall* (Sensibilidad), especialmente relevante en contextos clínicos para la detección temprana de la enfermedad (45).

El ROC-AUC se utilizó como métrica global de discriminación, permitiendo evaluar la capacidad del modelo para distinguir entre clases a distintos umbrales de decisión (46). El F1-score se empleó para equilibrar precisión y sensibilidad, mientras que con la especificidad se analizó la correcta identificación de los pacientes sanos (16,47).

3.3.3 Validación cruzada

En el paso de validación, se empleó la validación cruzada estratificada de 5 particiones (Stratified 5-Fold Cross-Validation) (39,40), utilizando *recall* como métrica principal. La validación cruzada tenía el fin de evaluar la estabilidad de los modelos. Sin embargo, esta validación se empleó como un análisis complementario para reforzar las comparaciones entre modelos, antes de la fase de optimización.

Los resultados obtenidos (Figura 5) mostraron que el modelo con mayor *recall* medio fue *Random Forest* ($0,850 \pm 0,042$), seguido de *XGBoost* ($0,828 \pm 0,043$) y *SVC* ($0,810 \pm 0,044$), los cuales presentaban un rendimiento similar, pero *SVC* con valores inferiores. El algoritmo que presentaba peor rendimiento era Regresión Logística, con un *recall* de 0,707 y un rango de variabilidad más amplio (0,067), lo que se traduce en menor estabilidad. En síntesis, los modelos basados en árboles presentaban los rangos de variabilidad más bajos, indicando mayor estabilidad.




Figura 5. Resultados de las métricas recall y rango de variabilidad en validación cruzada (5-fold).

3.3.4 Optimización de hiperparámetros

Una vez identificado el modelo con mejor valor de la métrica *recall*, se procedió a la optimización de hiperparámetros (21,22) mediante GridSearchCV. El objetivo de este paso era encontrar la mejor combinación de hiperparámetros.

La configuración óptima obtenida para *Random Forest* fue: *max_depth*: 10, *min_samples_leaf*: 1, *min_samples_split*: 2, y *n_estimators*: 200. Permitiendo mejorar el score de *recall* en validación cruzada de 0,7222 a 0,8625. Sin embargo, al evaluar el modelo optimizado sobre el conjunto de prueba, no se observaron mejoras en comparación con el modelo original. Este comportamiento pudo deberse a un sobreajuste (14) durante la optimización, debido a esto, se mantuvo el modelo original ya que mostraba mejor capacidad de generalización.

3.3.5 Modelo final seleccionado

Finalmente, el modelo seleccionado fue *Random Forest*. Pese que el modelo que presentaba más métricas (F1-score, accuracy, precision y specificity) con mayores resultados era *SVC*. Sin embargo, la decisión del modelo no se basó únicamente en métricas globales, sino en aquellas que estaban más alineadas con el objetivo clínico del

estudio (15,46). Estas métricas son las que respondían mejor al problema planteado. Por esta razón, *Random Forest* (44) fue el mejor modelo, presentando un equilibrio entre sensibilidad, estabilidad, y capacidad de discriminación (ROC-AUC).

El modelo permitió detectar correctamente el 72,2% de los casos de diabetes en el conjunto de prueba, manteniendo una especificidad cercana a 74%. Su capacidad para modelar relaciones no lineales y su interpretabilidad mediante la importancia de variables lo convertía en una opción adecuada para este problema clínico.

3.3.6 Implementación y despliegue

Se realizó la exportación del modelo final junto los elementos de preprocesamiento mediante la librería *joblib*. Se desarrolló una función de predicción para facilitar su implementación en un entorno aplicado. El personal médico introduciría los datos de un nuevo paciente, indicando el valor de las variables predictivas, y se obtendría una salida. En esta salida se especificará la predicción, ausencia o presencia de diabetes, la probabilidad asociada a padecer la enfermedad y una categorización del riesgo.

La función de predicción incluye el flujo de procesamiento de los datos seguidos en este estudio. Es decir, que las etapas aplicadas durante el entrenamiento son las mismas. Así garantiza la coherencia del modelo para su uso en un escenario real como una herramienta de apoyo a la decisión clínica (CDSS) (48,49).

4.Resultados y Discusión

4.1 Análisis exploratorio

El análisis exploratorio inicial permitió identificar la presencia de patrones relevantes en la estructura del conjunto de datos, y en la relación entre las variables predictoras y la variable objetivo. Uno de los hallazgos más importante fue la presencia de valores no plausibles en varias variables clínicas: *Glucose*, *BloodPressure*, *SkinThickness*, *Insulin* y *BMI*. Estos valores fueron interpretados como información que faltaba que había sido codificada como 0 (8). Este fenómeno era frecuente en bases de datos clínicas históricas. Es importante su detección para evitar la afectación de la calidad del dato, con la consecuente afectación de la calidad del modelo (26,29).

Tras la conversión de los valores a nulos explícitos y su posterior imputación, se observó una relativa estabilidad en las distribuciones de las variables, sobre todo en aquellas en las que el porcentaje de *missing values* eran menor. En variables con una mayor cantidad de valores ausentes, como *Insulin* y *SkinThickness*, la imputación produjo un cierto suavizado de la variabilidad, comportamiento que resultaba esperable dada el porcentaje elevado. Este comportamiento sugiere que la estrategia que se siguió en el preprocesamiento permitió conservar la estructura global de la información, sin introducir distorsiones excesivas. (27)




Figura 6. Scatterplot de la relación de la variable Glucosa y BMI con Outcome.

Gracias al análisis de correlación (Figura 6), se evidenció que *Glucose* era la variable con mayor asociación con presencia de diabetes, seguida de *BMI* e *Insulin*. Estas asociaciones son consistentes con la literatura clínica de la enfermedad y su fisiopatología. La hiperglucemia constituye el rasgo más vinculado al diagnóstico de la enfermedad (1), mientras que el índice de masa corporal y la insulina se relacionan con el estado metabólico y la resistencia a la insulina (34). Asimismo, en los diagramas de cajas de dichas variables se confirmaba las diferencias significativas existente entre los dos grupos, con diabetes y sin diabetes. Por tanto, estas variables aportaban capacidad discriminativa al modelo (22).

Por otra parte, la distribución de la variable objetivo (Figura 4) confirmó un desbalanceo de clases, con mayor número de casos negativos. El desequilibrio es relevante porque puede causar un sobreajuste, de manera que aprende mejor la clase mayoritaria, y reduce su capacidad de detectar correctamente los casos de diabetes. Es decir, puede dar lugar a un aumento de los falsos negativos (36).

4.2 Comparación de modelos

La comparación inicial de los 4 modelos (Tabla 3) evaluados permitió observar diferencias claras en el comportamiento predictivo. En términos generales, los algoritmos basados en estructuras complejas mostraron un rendimiento superior a la Regresión Logística. Esto puede indicar que la relación entre las variables predictoras y la objetivo no sea necesariamente lineal (22). De hecho, la diabetes es una enfermedad multifactorial que cuenta con la presencia de interacciones metabólicas y demográficas, es decir, que concuerda con que no siga una distribución lineal (34).

Al analizar las métricas de evaluación se observa que el modelo con mayor cantidad de métricas que presentaban mayores valores era SVC (sensibilidad: 0,7222, F1-score: 0,6724, exactitud: 0,7532, precisión: 0,629 y especificidad: 0,77). Aun así, las métricas más importantes para la selección del modelo predictor en este estudio eran sensibilidad y ROC-AUC. Los resultados de la métrica de sensibilidad mostraban que tanto Random Forest como SVC y XGBoost presentaban valores de sensibilidad $>0,7$, destacando Random Forest y SVC (0,7222 ambos). En último lugar se encontraba el algoritmo de Regresión Logística con un 0,6852 de especificidad.

Comparativa de modelos de clasificación						
Modelo	Recall (Sensibilidad)	ROC-AUC	F1-score	Accuracy	Precision	Specificity
Random Forest	0.7222	0.8293	0.6555	0.7338	0.6	0.74
SVC	0.7222	0.8152	0.6724	0.7532	0.629	0.77
XGBoost	0.7037	0.8209	0.6609	0.7468	0.623	0.77
Logistic Regression	0.6852	0.8085	0.6271	0.7143	0.5781	0.73

Tabla 3. Tabla comparativa de métricas de los 4 modelos.

En términos de ROC-AUC, Random Forest era el algoritmo que presentaba el valor más alto (0,8293), por lo tanto, era el que había alcanzado una capacidad discriminativa global más alta. Estos resultados resultaron importantes porque la sensibilidad refleja la capacidad del modelo para identificar correctamente a los pacientes con diabetes, y ROC-AUC expresa, de una forma más global, cómo de bueno es el modelo para separar ambas

clases a distintos umbrales de decisión. En el contexto clínico ambas métricas son esenciales (6).

El modelo de Regresión Logística presentó los valores más bajos de rendimiento entre los cuatro modelos. Puede ser un indicador de que el problema no sigue relaciones lineales, sino no lineales. Aunque la Regresión Logística es un método útil ya que es sencillo y fácil de interpretar, presenta una capacidad limitada de representar relaciones complejas. Debido a esta característica, su comportamiento fue peor que no los modelos basados en árboles o ensamblados (10).




Figura 7. Heatmap de matrices de confusión por modelo.

El análisis de las matrices de confusión (Figura 7) mostró que había una relación entre los modelos que habían obtenido las métricas de sensibilidad más altas, y aquellos que presentaban un número de falsos negativos menor. El principal foco de atención clínica de este estudio era minimizar los falsos negativos, las celdas correspondientes a los casos de diabetes no detectados. La matriz de confusión evidenció que los modelos SVC y Random Forest eran los que presentaban el valor más bajo de falso negativos. Desde un

punto de vista de apoyo a la decisión clínica, es preferible que se incrementen los falsos positivos a costa de que se reduzca el riesgo de no detectar la enfermedad (6).

Debido a estos resultados, Random Forest era la opción más equilibrada. Presentó de los valores más altos de sensibilidad, mantuvo una capacidad discriminativa sólida, y estabilidad en la validación. Aun así, posteriormente se analiza la importancia de las variables predictivas en el modelo, para ver si estos resultados concuerdan con la realidad clínica.

4.3 Interpretación del modelo

La curva ROC del modelo final presentó un AUC de 0,8293 (Figura 8), muy superior al 0,5 del clasificador aleatorio. Este valor reflejó que el comportamiento del modelo supera el valor esperado por azar, por lo tanto, presenta una buena capacidad para clasificar correctamente nuevas observaciones. También se pudo comprobar en el gráfico ya que la curva ROC de Random Forest estaba claramente separada de la diagonal del clasificador aleatorio. Por lo tanto, se confirmó que la capacidad discriminativa del modelo era buena para distinguir entre pacientes diabéticos y no diabéticos a distintos umbrales de decisión (6,46).




Figura 8. Curva ROC del modelo Random Forest con clasificador aleatorio 0,5.

El análisis de importancia de variables en el modelo Random Forest (Figura 9) mostró que los niveles de glucosa era el predictor más relevante (importancia=0,2861, 100% relativo), en segundo lugar, *BMI* (0,1749, 61,1%), seguida de *Age* (0,1256, 43,9%), *DiabetesPedigreeFunction* (0,1114, 38,9%) e *Insulin* (0,1027, 35,9%). Estos resultados son clínicamente coherentes, la variable más vinculada al diagnóstico de diabetes es la glicemia (1). El índice de masa corporal se relaciona con obesidad y resistencia a la insulina, y la edad es un factor de riesgo ampliamente documentado (34). La función de pedigrí diabético también aporta información relevante, refleja la predisposición familiar o genético, que puede influir en la probabilidad de desarrollar diabetes (50).




Figura 9. Gráfico de importancia de características predictoras en el modelo Random Forest.

La posición de *Insulin* en el análisis de importancia, puede explicarse por la elevada proporción de valores faltantes que presentaba al inicio (48,70%). Aunque la imputación permitió completar los valores faltantes de la variable, es posible que su señal original se diluyese en el proceso (26,50). Es decir, que al imputar la variable con estimaciones sintéticas derivadas de KNN, la información real de la variable insulina quedó reemplazada. Esto redujo su peso en el modelo y así obtuvo este resultado (27). Este sería un ejemplo de las implicaciones que tiene la calidad de los datos en la utilidad de las variables dentro del modelo, pese a que sea conocida su relevancia clínica.

Cabe destacar que la correlación de Pearson de *Insulin* con *Outcome* ($r=0,30$) en el análisis exploratorio, no concuerda con la importancia de la variable en el modelo de Random Forest. Esta aparente contradicción se debe a que la correlación de Pearson y la importancia de variables en Random Forest miden cosas distintas. El *heatmap* se calculó a través de los registros validos excluyendo los NaNs, mientras que la importancia de las variables en el modelo se calculó sobre el *dataset* completo e imputado. Es decir, que prácticamente la mitad de los registros de *Insulin* fueron estimaciones sintéticas generadas por KNN. La introducción de estos valores imputados redujo la señal predictiva real de la variable, diluyendo la capacidad discriminativa de los árboles de decisión. Dichos algoritmos, no dependen de relaciones lineales simples, sino de divisiones secuenciales del espacio de características (51).

En conjunto, los resultados sugieren que el modelo final seleccionado es Random Forest presentando capacidad para discriminar correctamente a los pacientes, y, una interpretación consistente con la evidencia clínica. Podría ser una herramienta útil en la ayuda de toma de decisiones clínicas, siempre bajo la supervisión y sin sustituir el juicio médico.

5. Conclusiones

En este Trabajo de Fin de Máster se desarrolló y evaluó un sistema de clasificación supervisado para la predicción de diabetes mellitus tipo II en mujeres a partir del *Pima Indians Diabetes Database*. Para ello, se compararon cuatro algoritmos de aprendizaje automático: Regresión Logística, *SVC*, *XGBoost* y *Random Forest*. El objetivo era identificar el modelo más adecuado para la priorización de la detección de casos positivos.

Los resultados obtenidos muestran que el modelo con mejor comportamiento global fue *Random Forest*. Presentó un equilibrio entre sensibilidad y capacidad discriminativa. Este modelo alcanzó una sensibilidad de 72,2% y un valor de ROC-AUC de 0,8293. Estos datos se traducen en un rendimiento aceptable para un entorno de exploración clínica, pero todavía insuficientes para implementarlo como un sistema de cribado definitivo. Detectó correctamente 39 de los 54 casos positivos de diabetes, con un total de 15 falsos negativos. El modelo fue capaz de captar una parte importante de los pacientes en riesgo, pero presentaba aún un margen de mejora para los falsos negativos. Aunque los resultados son funcionales para un CDSS, debería realizarse una mejora del modelo para implementarse como una herramienta de cribado poblacional (46).

Uno de los hallazgos más consistentes del estudio fue que la glucosa era el predictor más relevante para el modelo, tal y como se ve en la literatura clínica. Seguida del IMC y la edad, consistentes con factores de riesgo para la diabetes tipo II. Esta jerarquía de importancia coincide con la evidencia clínica de los principales factores asociados a la diabetes de tipo II. La glucosa refleja la alteración metabólica de la enfermedad, mientras que el índice de masa corporal y la edad son factores de riesgo asociados (1,34). Es decir, que los resultados aparte de ser estadísticamente consistentes, son también clínicamente plausibles.

El pipeline de preprocesamiento de estudio incluyó el análisis exploratorio del *dataset*, la identificación de valores no plausibles, su conversión a valores nulos (NaNs), la división de los datos en conjunto de entrenamiento y prueba, la imputación del conjunto de entrenamiento mediante la mediana o KNN según la tasa de valores faltantes, el balanceo de clases mediante SMOTE y el escalado de variables, resultó adecuado para la preparación de los datos de forma reproducible y consistente (18,19,26). Este pipeline

permitió entrenar a los modelos con datos más limpios y de mejor calidad, reduciendo los problemas debido a la baja calidad del dato.

Aun así, debe enfatizarse que el modelo desarrollado no sustituye a la evaluación clínica. Tampoco puede interpretarse como una herramienta diagnóstica aún, ya que precisa de mejoras, como por ejemplo la optimización de la sensibilidad y la reducción de falsos negativos. Su valor principal reside en el posible uso como sistema de apoyo a la decisión clínica, pudiendo orientar la identificación temprana de los pacientes con riesgo aumentado de diabetes. Es decir, podría utilizarse como una fase preliminar de cribado, pero siendo complementado con pruebas clínicas y la supervisión de los profesionales sanitarios (48).

6. Limitaciones y Trabajo futuro

A pesar de los resultados obtenidos, este estudio presentó varias limitaciones que deben de tenerse en cuenta al interpretar las conclusiones. En primer lugar, la primera limitación está relacionada con el *dataset* utilizado para el entrenamiento del modelo. El *dataset Pima Indians Diabetes Database* incluye exclusivamente a mujeres de origen indígena Pima mayores de 21 años. Es una restricción poblacional muy concreta que limita la generalización de los resultados a otros grupos demográficos, ya que las características metabólicas, genéticas y epidemiológicas de esta población pueden diferir de las otras poblaciones (23,52). Por lo tanto, no se trata de un modelo universal, se debe considerar más una aproximación dentro del contexto específico del conjunto de datos utilizado.

La segunda limitación es la elevada proporción de datos faltantes que presenta el *dataset*. Gran parte de la proporción se concentra en variables relevantes como *Insulin* y *SkinThickness*. Aunque se aplicaron métodos de imputación teniendo en cuenta las proporciones de datos faltantes para cada una de las variables, la gran cantidad de estos valores pudo haber reducido la representatividad real de estas. La consecuencia es la afectación de la capacidad predictiva en el modelo final. Por ejemplo, *Insulin* su señal original pudo verse atenuada por la reconstrucción de gran parte de sus valores mediante estimaciones sintéticas (26,27).

La tercera limitación tiene que ver con el rendimiento del modelo, concretamente con los niveles de sensibilidad (45). Aunque la sensibilidad del modelo final fuese razonable para un estudio exploratorio (72,2%), su sensibilidad sigue estando por debajo del que se pediría en una herramienta de cribado clínico robusta. Se requeriría una sensibilidad más alta ya que el objetivo es reducir al máximo los falsos negativos para que la enfermedad no pase desapercibida. Para ello, es necesaria una optimización del modelo antes de su aplicación (53).

Otra limitación es que el estudio solo ha utilizado un conjunto de datos históricos y no ha sido validado externamente en otras bases de datos o en otros entornos clínicos. Sin esta validación, el modelo debe interpretarse con cautela, ya que la validación sirve para comprobar si el rendimiento se mantiene en poblaciones distintas y en condiciones reales.

Es decir, que aún no se trata de una herramienta lista para su implementación en el flujo habitual de clínica (54).

Como líneas de trabajo futuro para este modelo se propone validarlo en *dataset* más heterogéneos y representativos de la población general, para la ampliación de su evaluación (54). También sería útil la incorporación de variables clínicas adicionales con potencial predictor de diabetes como HbA1c, antecedentes familiares, hábitos de vida o marcadores inflamatorios. Estas variables podrían mejorar la capacidad discriminativa del modelo (35).

Asimismo, sería interesante la exploración de técnicas de ajuste del umbral de decisión para incrementar la sensibilidad a costa de la especificidad, adecuado cuando se requiere un cribado en fases tempranas. Otra posible línea de futuro para la mejora del modelo podría ser probar modelos más avanzados o estrategias de ensamblado adicionales, calibrar las probabilidades de salida para facilitar uso clínico. Finalmente, sería deseable implementar el modelo en un entorno de validación prospectiva para evaluar la utilidad práctica en condiciones de uso habitual de asistencia sanitaria (35).

7. Bibliografia

1. Committee ADAPP, ElSayed NA, Aleppo G, Bannuru RR, Bruemmer D, Collins BS, et al. 2. Diagnosis and Classification of Diabetes: Standards of Care in Diabetes—2024. *Diabetes Care*. 1 de enero de 2024;47(Supplement_1):S20-42. doi:10.2337/dc24-S002 PubMed PMID: 38078589.
2. Diabetes [Internet]. Disponible en: <https://www.who.int/news-room/fact-sheets/detail/diabetes>
3. Urgent action needed as global diabetes cases increase four-fold over past decades [Internet]. Disponible en: <https://www.who.int/news/item/13-11-2024-urgent-action-needed-as-global-diabetes-cases-increase-four-fold-over-past-decades>
4. Magliano DJ, Boyko EJ, committee DA 11th edition scientific. 3. The global picture of diabetes [Internet]. 2025 Disponible en: <https://www.ncbi.nlm.nih.gov/books/NBK618744/>
5. Zhang J, Zhang Z, Zhang K, Ge X, Sun R, Zhai X. Early detection of type 2 diabetes risk: limitations of current diagnostic criteria. *Front Endocrinol (Lausanne)*. 2023;14:1260623. doi:10.3389/fendo.2023.1260623
6. Hajian-Tilaki K. Receiver Operating Characteristic (ROC) Curve Analysis for Medical Diagnostic Test Evaluation. *Caspian J Intern Med*. 2013;4(2):627. PubMed PMID: 24009950.
7. Nassiwa F, Zeng J. Evaluating Traditional Machine Learning Models for Predicting Diabetes Onset Using the Pima Indians Dataset. *Ann Med Health Sci Res* [Internet]. 2024;14:1010-5. Disponible en: <https://www.amhsr.org/articles/evaluating-traditional-machine-learning-models-for-predicting-diabetes-onset-using-the-pima-indians-dataset-12913.html>
8. R: Pima Indians Diabetes Database [Internet]. Disponible en: <https://search.r-project.org/CRAN/refmans/mlbench/html/PimaIndiansDiabetes.html>

9. Sigillito V. Description: 1. Title: Pima Indians Diabetes Database 2. Sources: (a) Original owners: National Institute of Diabetes and Digestive and Kidney Diseases (b) Donor of database [Internet]. Report. Disponible en: <http://archive.ics.uci.edu/ml/machine-learning-databases/pima-indians-diabetes/pima-indians-diabetes.data>

10. Bewick V, Cheek L, Ball J. Statistics review 14: Logistic regression. Crit Care. febrero de 2005;9(1):112. doi:10.1186/cc3045 PubMed PMID: 15693993.

11. Belgiu M, Drăgu L. Random forest in remote sensing: A review of applications and future directions. ISPRS Journal of Photogrammetry and Remote Sensing. 1 de abril de 2016;114:24-31. doi:10.1016/j.isprsjprs.2016.01.011

12. Chen T, Guestrin C. XGBoost: A Scalable Tree Boosting System [Internet]. 10 de junio de 2016. doi:10.1145/2939672.2939785

13. SVC — scikit-learn 1.8.0 documentation [Internet]. Disponible en: <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html>

14. Fernández-Delgado M, Cernadas E, Barro S, Amorim D, Fernández-Delgado A. Do we Need Hundreds of Classifiers to Solve Real World Classification Problems? Journal of Machine Learning Research [Internet]. 2014. Report. Disponible en: <http://www.mathworks.es/products/neural-network>.

15. Saito T, Rehmsmeier M. The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLoS One. 4 de marzo de 2015;10(3):e0118432. doi:10.1371/journal.pone.0118432 PubMed PMID: 25738806.

16. Chicco D, Jurman G. The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. BMC Genomics. 2 de enero de 2020;21(1):6. doi:10.1186/s12864-019-6413-7 PubMed PMID: 31898477.

17. Austin PC, White IR, Lee DS, van Buuren S. Missing Data in Clinical Research: A Tutorial on Multiple Imputation. *Can J Cardiol*. 1 de septiembre de 2021;37(9):1322. doi:10.1016/j.cjca.2020.11.010 PubMed PMID: 33276049.
18. Chawla N V, Bowyer KW, Hall LO, Kegelmeyer WP. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*. 2002. Report.
19. Patro SGK, sahu KK. Normalization: A Preprocessing Stage. *IARJSET*. 20 de marzo de 2015;20-2. doi:10.17148/iarjset.2015.2305
20. 3.1. Cross-validation: evaluating estimator performance — scikit-learn 1.8.0 documentation [Internet]. Disponible en: https://scikit-learn.org/stable/modules/cross_validation.html
21. Bergstra J, Ca JB, Ca YB. Random Search for Hyper-Parameter Optimization Yoshua Bengio. *Journal of Machine Learning Research* [Internet]. 2012. Report. Disponible en: <http://scikit-learn.sourceforge.net>.
22. Sarker IH. Machine Learning: Algorithms, Real-World Applications and Research Directions. *SN Comput Sci*. 1 de mayo de 2021;2(3):160. doi:10.1007/s42979-021-00592-x PubMed PMID: 33778771.
23. Using the ADAP Learning Algorithm to Forecast the Onset of Diabetes Mellitus - PMC [Internet]. Disponible en: <https://pmc.ncbi.nlm.nih.gov/articles/PMC2245318/>
24. Pearson ER. Dissecting the Etiology of Type 2 Diabetes in the Pima Indian Population. *Diabetes*. 1 de diciembre de 2015;64(12):3993-5. doi:10.2337/dbi15-0016 PubMed PMID: 26604175.
25. Zhu J, Pu S, He J, Su D, Cai W, Xu X, et al. Processing imbalanced medical data at the data level with assisted-reproduction data as an example. *BioData Min*. 1 de diciembre de 2024;17(1):29. doi:10.1186/s13040-024-00384-y PubMed PMID: 39232851.
26. Jakobsen JC, Gluud C, Wetterslev J, Winkel P. When and how should multiple imputation be used for handling missing data in randomised clinical trials – a practical

guide with flowcharts. BMC Med Res Methodol. 6 de diciembre de 2017;17(1):162. doi:10.1186/s12874-017-0442-1

27. Jerez JM, Molina I, García-Laencina PJ, Alba E, Ribelles N, Martín M, et al. Missing data imputation using statistical and machine learning methods in a real breast cancer problem. Artif Intell Med. 1 de octubre de 2010;50(2):105-15. doi:10.1016/j.artmed.2010.05.002 PubMed PMID: 20638252.

28. Austin PC, White IR, Lee DS, van Buuren S. Missing Data in Clinical Research: A Tutorial on Multiple Imputation. Can J Cardiol. 1 de septiembre de 2021;37(9):1322. doi:10.1016/j.cjca.2020.11.010 PubMed PMID: 33276049.

29. (PDF) An Analysis of Four Missing Data Treatment Methods for Supervised Learning. [Internet]. Disponible en: https://www.researchgate.net/publication/220355769_An_Analysis_of_Four_Missing_Data_Treatment_Methods_for_Supervised_Learning

30. Blanca MJ, Alarcón R, Arnau J, Bono R, Bendayan R. Datos no normales: ¿es el ANOVA una opción válida? Psicothema. 2017;29(4):552-7. doi:10.7334/psicothema2016.383 PubMed PMID: 29048317.

31. Chang V, Bailey J, Xu QA, Sun Z. Pima Indians diabetes mellitus classification based on machine learning (ML) algorithms. Neural Comput Appl. 1 de agosto de 2022;35(22):1. doi:10.1007/s00521-022-07049-z PubMed PMID: 35345556.

32. Mckinney W. Data Structures for Statistical Computing in Python. 2010. Report.

33. Kaufman S, Rosset S, Perlich C. Leakage in data mining: Formulation, detection, and avoidance. Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2011;556-63. doi:10.1145/2020408.2020496

34. Wondmkun YT. Obesity, Insulin Resistance, and Type 2 Diabetes: Associations and Therapeutic Implications. Diabetes Metab Syndr Obes. 2020;13:3611. doi:10.2147/DMSO.S275898 PubMed PMID: 33116712.

35. Kavakiotis I, Tsave O, Salifoglou A, Maglaveras N, Vlahavas I, Chouvarda I. Machine Learning and Data Mining Methods in Diabetes Research. *Comput Struct Biotechnol J*. 1 de enero de 2017;15(7453):104-16. doi:10.1016/j.csbj.2016.12.005 PubMed PMID: 28138367.
36. Krawczyk B. Learning from imbalanced data: open challenges and future directions. *Progress in Artificial Intelligence* 2016 5:4. 22 de abril de 2016;5(4):221-32. doi:10.1007/s13748-016-0094-0
37. Limpert E, Stahel WA. Problems with Using the Normal Distribution – and Ways to Improve Quality and Efficiency of Data Analysis. *PLoS One*. 2011;6(7):e21403. doi:10.1371/journal.pone.0021403 PubMed PMID: 21779325.
38. Cox NJ, Jones K. Exploratory data analysis. Report.
39. Raschka S. Model Evaluation, Model Selection, and Algorithm Selection in Machine Learning [Internet]. 11 de noviembre de 2020. Disponible en: <http://arxiv.org/abs/1811.12808>
40. Kim JH. Estimating classification error rate: Repeated cross-validation, repeated hold-out and bootstrap. *Comput Stat Data Anal*. 1 de septiembre de 2009;53(11):3735-45. doi:10.1016/j.csda.2009.04.009
41. Secondary Analysis of Electronic Health Records. Secondary Analysis of Electronic Health Records. Springer International Publishing; 2016. 1-427 p. doi:10.1007/978-3-319-43742-2
42. Troyanskaya O, Cantor M, Sherlock G, Brown P, Hastie T, Tibshirani R, et al. Missing value estimation methods for DNA microarrays. *BIOINFORMATICS* [Internet]. 2001. Report. Disponible en: <http://smi-web>.
43. Cortes C. Support-Vector Networks. Vol. 20. 1995. Report.
44. Breiman L. Random forests. *Mach Learn*. octubre de 2001;45(1):5-32. doi:10.1023/A:1010933404324

45. Increase effectiveness, maximize benefits and minimize harm Screening programmes: a short guide. Report.
46. Fawcett T. An introduction to ROC analysis. *Pattern Recognit Lett.* junio de 2006;27(8):861-74. doi:10.1016/j.patrec.2005.10.010
47. Park SH, Goo JM, Jo CH. Receiver Operating Characteristic (ROC) Curve: Practical Review for Radiologists. *Korean J Radiol.* 2004;5(1):11. doi:10.3348/kjr.2004.5.1.11 PubMed PMID: 15064554.
48. Sutton RT, Pincock D, Baumgart DC, Sadowski DC, Fedorak RN, Kroeker KI. An overview of clinical decision support systems: benefits, risks, and strategies for success. *npj Digital Medicine* 2020 3:1. 6 de febrero de 2020;3(1):17-. doi:10.1038/s41746-020-0221-y PubMed PMID: 32047862.
49. Esteva A, Chou K, Yeung S, Naik N, Madani A, Mottaghi A, et al. Deep learning-enabled medical computer vision. *NPJ Digit Med.* 1 de diciembre de 2021;4(1):5. doi:10.1038/s41746-020-00376-2 PubMed PMID: 33420381.
50. Prasad RB, Groop L. Genetics of Type 2 Diabetes—Pitfalls and Possibilities. *Genes (Basel).* 24 de diciembre de 2015;6(1):87. doi:10.3390/genes6010087 PubMed PMID: 25774817.
51. Hastie T, Tibshirani R, Friedman J. Springer Series in Statistics The Elements of Statistical Learning Data Mining, Inference, and Prediction. Report.
52. Pima Indians Diabetes Database [Internet]. Disponible en: <https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>
53. Cohen JF, Korevaar DA, Altman DG, Bruns DE, Gatsonis CA, Hooft L, et al. STARD 2015 guidelines for reporting diagnostic accuracy studies: explanation and elaboration. *BMJ Open.* 1 de noviembre de 2016;6(11):e012799. doi:10.1136/bmjopen-2016-012799 PubMed PMID: 28137831.
54. Steyerberg EW, Vickers AJ, Cook NR, Gerds T, Gonen M, Obuchowski N, et al. Assessing the performance of prediction models: a framework for some traditional and

novel measures. Epidemiology. enero de 2010;21(1):128.
doi:10.1097/EDE.0b013e3181c30fb2 PubMed PMID: 20010215.

8. Anexos

8.1. Anexo 1 - Código

El código utilizado para el desarrollo del presente trabajo se encuentra disponible en este anexo, mediante un enlace al notebook de Google Colab:

[https://colab.research.google.com/drive/14WBgmALAb8LLriNfyDegSov2epQNb3F1?
usp=sharing](https://colab.research.google.com/drive/14WBgmALAb8LLriNfyDegSov2epQNb3F1?usp=sharing)